


EvidScope 프로젝트 포트폴리오

AI 행동과 참고자료를 연결하는 감사 지원 서비스

업무 AI의 자기보고, 도구 결과, 권한과 참고자료를 대조하고 사람이 검토 근거를 남기는 로컬 파일럿이다. 보안·플랫폼 개발 관점에서 관측 가능한 사실, AI 검토 의견, 인간 판단의 경계를 설계했다.



AI 실행기에 Vault DB · 서명키 · 인간 감사자 토큰을 제공하지 않는 설계

프로젝트 성격	주요 기술	현재 단계
사용자 주도 AI 협업 개발	Node.js 24 · SQLite · 정적 JavaScript UI	실행 가능한 1차 파일럿
행동 가시성과 감사 지원	서명 원장 · Docker · Kubernetes · Ollama	실제 로컬 추론 확인 · 보안 보완 중

공개 운영·고객 도입·법률 인증·학습 완료를 주장하지 않는다. 실제 실험의 실패와 미확인 사항도 결과에 포함한다.

수치를 근거까지 따라갈 수 있는 화면

● 에이전트 목록

● 감사 API 연결됨

새로고침

감사 내보내기

검색 종료

EVIDENCE FIRST. HUMAN ACCOUNTABILITY.

에이전트 목록

조회 19시 6분 47초

에이전트별 정책 준수 현황

인증된 출처와 보고된 에이전트 이름을 함께 식별합니다. 평가 범위가 작으면 높은 비율도 전체 준수를 뜻하지 않습니다.

에이전트·모델·출처 검색

이름, qwen, 수집 출처...

조회 기간

최근 7일

우선 확인

전체 에이전트

정렬

위반 → 재검토 → 근거 부족

조회

검색된 에이전트

3

개 에이전트

위반 신호 있음

1

개 에이전트

근거 미확인 있음

2

개 에이전트

재검토 필요

1

개 에이전트

기간 내 행동 없음

0

개 에이전트

최근 7일 · 2026. 9. 2. 19시 6분 47초 ~ 2026. 9. 9. 19시 6분 47초 · 현재 평가 기준. 선택 기간에 첫 에이전트 기록이 수신된 행동의 현재 평가입니다. 기간 밖 연관 근거도 대조합니다. 과거 당시의 판정 또는 법적 준수율이 아닙니다. 파기로 보존 기록이 풀면 집계가 달라질 수 있습니다. 에이전트 미귀속 행동 2개 · 여러 에이전트 귀속 행동 0개. 중측 행동 / (중측 행동 + 위반 신호 행동). 미확인·분석 대기. 예외는 제외하며 평가 범위를 함께 표시합니다.

에이전트 / 출처	모델 / 최근 수신 (현재)	기간 내 행동	관측 정책 준수율	위반 / 미확인 / 대기 / 예외	인간 검토 / 참고자료	상세
support-agent alpha-agent	모델 미수집 2026. 9. 8. 15시 36분 41초	2	0% 중측 0 / 판정 가능 2개 행동 평가 범위 100% · 전체 2개 중	2 / 0 / 0 / 0	검토 0/2 · 참조 1/2	정책·근거 보기
local-qwen-pilot alpha-agent	qwen3.0.6b 2026. 9. 8. 21시 48분 56초	3	산정 불가 중측 0 / 판정 가능 0개 행동 평가 범위 0% · 전체 3개 중	0 / 3 / 0 / 0	검토 0/3 · 참조 1/3	정책·근거 보기

실제 에이전트 목록. 합성·로컬 시험 기록이며, 미확인인 산정 불가로 표시한다. 화면에 표시된 비율은 관측된 행동의 정책 평가이며 법적 준수율이 아니다.

설계 선택은 분모를 드러내는 것이다. 준수를 옆에 평가 범위를 표시하고, 각 행동의 자료·관한·결과로 이동하게 했다. 주시형 시간축은 확대·이동·최신 따라가기를 제공하며, 상세 조사와 주간 검토의 집계 간격을 구분한다.

2026.09.09 19:00 KST 기준 · 검증 기준 300c07f · 합성 데이터 파일럿

02

실험으로 확인한 결과와 개선 사례

관점	실제로 확인한 결과	해석의 범위
로컬 AI 지원	Qwen3 4B 실제 실행 10.90초 / 46.04초	서로 다른 합성 입력 2회, 평균 성능 아님
품질 문제 발견	참고자료 충돌·수집 공백 주장 일부의 인용 불충분	초안 시험상 반려, 실무 품질 승인 보류
내부 Service 분산	수집 60/60, 감사 60/60 · 각 2개 Pod	9월 8일 이전 구현, 외부 LB 시험 아님
HPA와 복구	replica 2 → 3 → 2, 성공접수 515건 보존	8 timeout 발생, 단일 PVC의 Pod 복구
적대적 감사	기존 지원 시험 8개 통과 후 추가 결함 5개 재현	조건부 P1 1개, P2 4개 · 수정 재검증 중

인용 ID 검증만으로 충분하지 않았던 사례

로컬 모델은 존재하는 기록을 인용했지만, 그 기록이 해당 주장을 지지하지 않는 경우가 있었다. 이 결과를 성공으로 포장하지 않고 반려 기록과 원본 초안을 함께 보존했다. 다음 조치는 선택 근거와 사건 전체 규칙 평가를 분리하고, 역할 평가에 인용 타당성과 근거 부족 감지를 추가하는 것이다.

두 AI 검토 기록은 자동화가 합성 인간 역할 자격으로 API·화면 경계를 검증한 결과다. 실제 사람의 내용 검수나 채택률 자료가 아니다. 성능·정확도 향상과 업무 시간 절감률은 아직 측정하지 않았다.

근거: reports/assistance-local-20260909.json · reports/assistance-ui-local-20260909.json · reports/astra-adversarial-20260909.md · reports/kubernetes-runtime-20260908.md

역할 분담과 포트폴리오 소개 문안

사용자는 사람이 판단할 수 있는 가시성을 우선 목표로 정하고, 로컬 모델 실증·Kubernetes 분산·역할별 에이전트·추가 API 비용 0원이라는 조건을 결정했다. 설계와 감사에는 Astra, 핵심 구현에는 Sol, UI에는 Claude를 배치한 AI 협업 프로젝트다. 아래와 같이 기획·판단과 구현 기여를 구분한다.

구분	산출물과 책임
사용자	문제 정의, 우선순위·모델·비용 조건 결정, 최종 검토와 공개 판단
Astra	아키텍처·개선 방향·독립 적대적 감사와 문서 정리
Sol	수집·API·저장·로컬 실행기·검증 및 통합 구현
Claude	팀·AI 지원 UI 초안 구현. 추가 UI 수정은 구독 한도로 보류

소개 글에 사용할 수 있는 문안

EvidScope는 AI 행동·도구 결과·권한·참고자료를 연결하는 감사 지원 파일럿입니다. 근거가 부족한 상태를 준수로 계산하지 않고, 실제 로컬 모델이 작성한 초안을 별도 검토 기록으로 관리하도록 구성했습니다. AI 협업 개발에서 설계·구현·UI·적대적 감사를 분리했으며, Kubernetes 분산·복구와 로컬 추론 시험에서 확인한 성과와 실패를 원자료로 남겼습니다.

다음 단계

보안 결함 수정과 재감사 → 개발 실행 이벤트와 역할 패키지 통합 → 인용 품질 평가 → UI 보완 → 최신 Kubernetes 및 격리 재검증 순으로 진행한다. 선택적 LoRA는 사람 검수 데이터와 평가 기준을 충족한 이후에 검토한다.

저장소 공개 주소와 실서비스 주소는 미확정이다. GitHub 업로드 완료나 고객 운영 실적으로 표기하지 않는다. 상세 구현 보고서는 함께 제공하는 EvidScope 1차 개발 보고서를 참조한다.

운영 원칙 추가: 테스트 외에는 모델·시험 위커를 중지한다. 19시 14분에 전용 모델·클러스터·로컬 시험 서버의 중지를 확인했으며, 자동 정리 도구는 구현 중이다.